

Modello predittivo del burning cost

Antonio Ferri
1 luglio 2026

1. Approccio e obiettivo

L'obiettivo è stimare, per ogni assicurato, il **burning cost**: il costo atteso dei sinistri per anno-uomo di esposizione. La grandezza si scompone naturalmente nel prodotto di due componenti:

$$\text{Burning cost} = \frac{\text{costo}}{\text{esposizione}} = \underbrace{\frac{\text{n. sinistri}}{\text{esposizione}}}_{\text{frequenza}} \times \underbrace{\frac{\text{costo}}{\text{n. sinistri}}}_{\text{severity}}$$

Ho scelto un approccio a due stadi separati: GLM di frequenza (Poisson) $\times$ GLM di severity (Gamma). Rispetto a un singolo GLM Tweedie, l'approccio spezzato è lo standard nella pratica: fornisce **fattori tariffari distinti** per frequenza e severity, permettendo di identificare dove agisce ogni driver di rischio, informazione direttamente utilizzabile nelle decisioni di pricing e nella gestione del portafoglio.

1.1 Dati e data preparation

Il dataset è composto da due tabelle: una popolazione esposta (riga per assicurato per anno di sottoscrizione, 79.000 righe) e i relativi sinistri (40.192 righe). Le chiavi `id_assicurato` e `id_caponucleo` cambiano ogni anno, mentre `id_nucleo` e `id_azienda` sono stabili.

1.1.1 Analisi esplorativa

L'esplorazione dei dati ha evidenziato:

- **Qualità dati:** Non ci sono valori mancanti nè duplicati: il dataset è già pulito a livello strutturale.
- **Anomalie:**
 1. La variabile esposizione, frazione di anno in cui la copertura è stata in vigore, presentava:
 - Valori uguali a zero, questo provocava burning cost non definito.
 - Valori maggiori di uno, anomali per definizione, essendo l'esposizione una frazione dell'anno in vigore.
 2. Individuato 52 sinistri orfani: presenti nella tabella sinistri ma privi di corrispondenza nella tabella degli assicurati.
- **uy:** Anno di sottoscrizione della polizza, codificato come 1 (2017), 2 (2018), 3 (2019), ricavato dalla data del sinistro nella tabella sinistri.
- **Anagrafica e attributi di polizza:** Settore dominato da TECH, BANKING, AUTOMOTIVE. Circa il 40% degli assicurati sono caponucleo, il resto familiari (figli, coniugi, conviventi). La categoria si concentra principalmente in dipendente qualificato e dipendente base, bassa presenza di pensionati. Forte concentrazione geografica nel Nord, particolarmente in Lombardia. Composizione nucleo varia da 1 a 8+, con moda in 3 e 4. Sesso maschile leggermente dominante. La popolazione include neonati (età 0) e anziani (fino a 92), coerente con un portafoglio che copre il dipendente e i suoi familiari.
- **Convenzione:** il 61% dei sinistri è fuori convenzione (24.000 vs 15.000); l'importo medio fuori convenzione è superiore, coerente con tariffe libere di mercato rispetto alle tariffe convenzionate.

1.1.2 Decisioni di pulizia

- **Esposizione = 0** (36 righe): escluse.
- **Esposizione > 1** (8 righe, max 1,01): cappate ad 1.
- **Importo = 0** (427 sinistri): mantenuti, prestazioni reali a costo nullo (contano in frequenza, non in severity).
- **Sinistri orfani:** esclusi, non agganciano alcun assicurato.
- **Grandi sinistri:** capping al 99,5 percentile, soglia stimata solo sul train per non introdurre leakage.

Analisi del target. Dopo la pulizia, tramite un merge tra le due tabelle, ho ottenuto una base modellabile di **78.964 righe**. Ho studiato la distribuzione delle variabili target per ricavare indicazioni dirette sulla scelta dei modelli:

- **Numero di sinistri (frequenza):** distribuzione con forte massa in zero (75,7% degli assicurati non genera sinistri), valori interi non negativi e coda a destra. La trasformazione $\log_{1p}$, applicata in fase esplorativa, linearizza la distribuzione. Questa forma è tipica di una **Poisson**, distribuzione naturale per conteggi di eventi rari, che motiva il modello scelto.
- **Costo per sinistro (severity):** distribuzione sempre positiva, fortemente asimmetrica a destra (pochi sinistri molto costosi), con mediana (76,5 euro) molto inferiore alla media (92 euro). Anche qui la trasformazione $\log_{1p}$ linearizza la distribuzione. Questa forma motiva la scelta della **Gamma**: cattura l'asimmetria a destra senza ammettere valori negativi, a differenza della normale.
- **Burning cost:** media di portafoglio 49 euro per anno-uomo (frequenza $0,53 \times \text{severity}$ 92), ma la mediana è zero, mentre la media è fortemente influenzata dalla minoranza di assicurati sinistrati. Questa struttura conferma che stimare direttamente il burning cost su tutti gli assicurati sarebbe inappropriato: l'approccio a due stadi (frequenza $\times$ severity) è più corretto.

Split temporale Per simulare l'uso reale del modello (prevedere il futuro a partire dal passato), ho diviso i dati nel tempo, anziché casualmente: **stima sugli anni di sottoscrizione 1 e 2** (train, 54.456 righe), **test sull'anno 3** (24.508 righe). Una divisione casuale avrebbe mescolato gli anni, distorcendo le performance; lo split out-of-time misura la reale capacità di generalizzare a un anno mai visto.

2. Feature engineering

Ho costruito un insieme ampio di variabili candidate, per poi selezionare nel modello solo un sottoinsieme ridotto e interpretabile. Tutte le feature sono disponibili al momento del pricing, per non avere problemi di *leakage*.

Variabili costruite. A partire dai dati grezzi ho derivato:

- **Fasce di età:** Discretizzazione dell'età continua, cattura la non linearità a J del rischio sanitario (alto nei bambini, basso nei giovani-adulti, crescente negli anziani).
- **Struttura del nucleo:** Variabili aggregate a livello `id_nucleo`, composizione numerica (numero di componenti), numero di assicurati, età media/minima/massima del nucleo, età del caponucleo, numero di figli, flag presenza figli e presenza anziani.
- **Dimensione azienda:** Numero di assicurati per azienda, in scala logaritmica, il log comprime la leva delle poche aziende molto grandi, ottenendo un effetto più regolare al crescere della dimensione.

Variabili usate nel modello. Tra tutte le candidate (costruite + grezze), il modello usa:

- **Categoriche:** fascia di età, sesso, categoria, legame familiare, settore, macroarea.
- **Numeriche:** composizione numerica del nucleo (`composizione_num`), dimensione azienda in scala log (`log_dim_azienza`).
- **Interazione:** fascia di età $\times$ sesso (specificata nella formula del modello). Nella salute il profilo di rischio per età differisce tra uomini e donne (picco di frequenza femminile in età fertile, legato alla maternità), un effetto solo additivo non coglierebbe.

Variabili scartate. Le restanti sono escluse per collinearità o ridondanza con variabili già presenti nel modello:

- `eta_media/min/max_nucleo` ed `eta_caponucleo`: assorbite dalla fascia di età individuale;
- `presenza_figli/anziani`: assorbite da legame familiare e fascia di età;
- `regione`: sostituita da `macroarea`, meno livelli;
- `carico_fiscale` e `tipo_assicurato`: attributi fortemente legati a legame familiare ed età, quindi con scarso contenuto informativo aggiuntivo.

Controllo del data leakage. Sono escluse dai predittori tutte le grandezze note solo dopo l'accadimento del sinistro: la convenzione e ogni quantità dell'anno corrente derivata dal target. La variabile `uy` non è usata come predittore.

3. Modellazione

Perché un GLM. Nel pricing il GLM è lo standard di settore perché è interpretabile (ogni coefficiente è un fattore tariffario), adatto a risposte non gaussiane (conteggi, costi) e lineare nei parametri.

Un GLM generalizza la regressione lineare rilassando le assunzioni su **due fronti**, la distribuzione della risposta e il legame tra media e predittore, tramite tre componenti:

1. **Componente casuale:** la risposta Y_i appartiene alla famiglia esponenziale; scelgo la distribuzione più adatta alla forma del target (Poisson per i conteggi, Gamma per i costi), rilassando l'assunzione di normalità della regressione classica.

2. **Predittore lineare:** come nella regressione classica, $\eta_i = x_i^\top \beta = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$. È sempre lineare nei parametri: è questo che mantiene il modello interpretabile.
3. **Funzione di legame g :** collega la media $\mu_i = E[Y_i]$ al predittore, $g(\mu_i) = \eta_i$. Il legame può essere non lineare; la scelta è il **legame logaritmico** $g(\mu) = \log \mu$, per entrambi i modelli. La cui motivazione è illustrata a seguire.

Legame log e moltiplicatori tariffari. Con il legame logaritmico la media in scala log è il predittore lineare, quindi la media è il suo esponenziale:

$$\log \mu_i = \beta_0 + \sum_j \beta_j x_{ij} \implies \mu_i = e^{\beta_0} \prod_j e^{\beta_j x_{ij}}$$

Il modello diventa **moltiplicativo**: e^{β_0} è il rischio base (riferimento) e ogni $\exp(\beta_j)$ è il **fattore tariffario** che moltiplica tale rischio. (es. $\exp(\beta_j) = 1,40$ indica +40% rispetto al riferimento, a parità delle altre variabili.)

Frequenza (GLM Poisson con offset). Il numero di sinistri N_i è un conteggio di eventi rari (intero, con molti zeri): la distribuzione naturale è la Poisson. Voglio però che il predittore descriva il tasso per anno-uomo λ_i , non il conteggio grezzo; poiché $\lambda_i = \mu_i / e_i$, l'esposizione (anni-uomo e_i) entra come **offset**, un termine noto a coefficiente fisso a 1:

$$N_i \sim \text{Poisson}(\mu_i), \quad \log \mu_i = \log e_i + x_i^\top \beta$$

Esponenziando, l'offset additivo nel log diventa un fattore moltiplicativo nella media: $\mu_i = e_i \exp(x_i^\top \beta)$. Così l'esposizione scala il conteggio, mentre il tasso $\lambda_i = \exp(x_i^\top \beta)$, il rischio per anno-uomo, è indipendente dal tempo di copertura.

Severity (GLM Gamma con pesi). Il costo per sinistro S_i è positivo e asimmetrico a destra: la distribuzione naturale è la Gamma, che a differenza della normale vive solo sui valori positivi e cattura la coda a destra.

$$S_i \sim \text{Gamma}(\nu_i, \phi), \quad \log \nu_i = x_i^\top \gamma$$

dove ν_i è il costo medio per sinistro. La stima usa solo i sinistrati $\{i : N_i > 0\}$; qui il ruolo che nella frequenza aveva l'esposizione lo gioca il numero di sinistri: S_i è la media dei costi degli N_i sinistri dell'assicurato, e la media di più sinistri è più stabile. Il numero di sinistri entra perciò come **peso**: chi ha più sinistri pesa di più nella stima del costo medio.

Burning cost. Combinando i due modelli, il burning cost per anno-uomo è il prodotto del tasso di frequenza e del costo medio per sinistro:

$$\text{BC}_i = \lambda_i \cdot \nu_i = \exp(x_i^\top \beta) \exp(x_i^\top \gamma)$$

Poiché entrambe le componenti sono moltiplicative, anche i fattori tariffari si combinano per prodotto: il fattore sul burning cost di un segmento è il fattore di frequenza moltiplicato per quello di severity.

4. Risultati e validazione

Fattori tariffari. La decomposizione mostra dove agisce ogni driver (Tabella 1), i pensionati fanno molti più sinistri (frequenza 3,4×) ma di costo simile (severity 1,2×), quindi il loro driver è la frequenza; i dirigenti hanno invece la severity più alta tra le categorie (1,3×). La separazione frequenza e severity è il valore aggiunto dell'approccio spezzato: ogni driver è leggibile sulla componente su cui agisce.

Fattore (vs riferimento)	Frequenza	Severity
Categoria: PENSIONATI	3,4×	1,2×
Categoria: DIRIGENZIALE	2,1×	1,3×
Categoria: DIP. QUALIFICATO	1,9×	1,2×
Età: 75+	1,8×	1,1×

Tabella 1: Principali moltiplicatori tariffari. Riferimenti: dipendente base (categoria), fascia 0–17 (età).

Validazione

- **Calibrazione complessiva:** A/E sul costo totale = **1,04** (scarto 4%); un rescale del livello azzera la differenza senza alterare l'ordinamento.
- **Ordinamento del rischio:** Gini = **0,46**, IC 95% [**0,44; 0,47**] (robusto). La lift table (Fig. 1) è quasi monotona: i clienti previsti più rischiosi sono davvero più costosi. La calibrazione per decile è buona nei decili medio-alti (8–10, A/E≈0,99) e meno nei bassi, dove il modello tende a sovrastimare, atteso con forte zero-inflation.
- **A/E per segmento** (Tabella 2): i segmenti principali sono ben calibrati (dirigenti 1,03, pensionati 1,01); gli scostamenti si concentrano sui giovani 18–30 (1,17) e sui pochi 75+ (0,86), base per eventuali azioni correttive sul pricing.




Figura 1: Lift table sul test: burning cost previsto vs osservato per decile di rischio

Segmento	n	Esposizione	BC oss.	BC prev.	A/E
<i>Fascia età</i>					
0-17	6.237	5.965	37,0	33,0	1,12
18-30	3.391	3.171	40,3	34,4	1,17
31-45	7.881	7.517	52,5	53,1	0,99
46-60	6.162	6.029	57,6	57,2	1,01
61-75	762	729	79,7	67,4	1,18
75+	75	75	78,4	91,4	0,86
<i>Categoria</i>					
DIP_BASE	7.334	7.011	24,4	24,7	0,99
DIP_QUALIFICATO	13.790	13.230	60,9	57,3	1,06
DIRIGENZIALE	1.502	1.459	98,2	95,3	1,03
PENSIONATI	179	179	132,3	131,2	1,01
<i>Macroarea</i>					
NORD-OVEST	12.433	11.954	63,0	60,4	1,04
NORD-EST	5.595	5.295	13,0	14,8	0,88
CENTRO	4.845	4.647	54,7	51,9	1,05
SUD E ISOLE	1.607	1.561	49,1	41,0	1,20
<i>Sesso</i>					
F	11.873	11.373	57,2	57,1	1,00
M	12.635	12.113	41,6	37,7	1,10

Tabella 2: A/E per segmento sul test

5. Limiti e opportunità di miglioramento

- **Correlazione intra-nucleo:** I membri dello stesso nucleo condividono fattori non osservati (stile di vita, contesto familiare), ad esempio, se il caponucleo va in visita, probabilmente porta con sé figli o coniuge. Si potrebbe usare un modello a effetti misti (GLMM), che aggiunge un valore di base specifico per ogni nucleo.
- **Tempo limitato:** i dati disponibili coprono solo 3 anni di sottoscrizione, con un solo anno di test. Non posso verificare se la performance è stabile ripetendo lo split più volte e spostandolo nel tempo, né stimare un trend (es. inflazione medica). Più anni darebbero anche più osservazioni sui segmenti rari (es. la fascia 75+, oggi solo 75 assicurati nel test).
- **Linearità del GLM:** il modello cattura solo gli effetti specificati esplicitamente (variabili principali e l'interazione età×sesso); pattern non testati, altre interazioni, non linearità più fini, restano invisibili. Un modello non lineare (LightGBM) come challenger, con SHAP, potrebbe confermare o migliorare i driver del GLM, mantenuto in produzione per trasparenza e spiegabilità.
- **Settore:** Il settore aziendale approssima il rischio professionale ma non lo cattura del tutto (es. infortuni sul lavoro). L'arricchimento con statistiche esterne per settore (es. tassi INAIL) potrebbe aumentare il potere di ordinamento, senza introdurre leakage, sono dati noti prima della copertura.